

재난 관리용 고해상도 지형 데이터 자동 생성 방법 제안



이 종혁
서울대학교 농업생명과학연구원
/ 선임연구원
leejh314@snu.ac.kr



이상익
경북대학교 농업토목공학과
/ 조교수
sangik@knu.ac.kr



최원
서울대학교 조경·지역시스템
공학부 지역시스템공학전공,
글로벌스마트팜융합전공,
농업생명과학연구원 / 부교수
fembem@snu.ac.kr

1. 서언

재난 관리 분야에서 지리정보시스템 (geographic information system; GIS)은 다양한 데이터를 통합하고 분석할 수 있는 능력으로 인해 필수적인 도구로 자리 잡고 있다. GIS는 공간 데이터의 시각화, 분석, 관리 및 공유를 실시간으로 가능하게 하여 재난 발생 가능성을 예측하고 피해를 최소화하는 데 중요한 역할을 한다 (Daud et al., 2024). 특히 웹 기술을 기반으로 GIS 기능을 제공하는 Web-GIS는 전 세계에서 재난 대비 및 대응을 위한 표준으로 널리 활용되고 있다 (Ugliotti et al., 2023). 이러한 GIS 시스템의 효과적인 운영을 위해서는 실제 지형을 정확하게 반영한 지형 자료가 필요하며, DTM (digital terrain model), DEM (digital elevation model), DSM (digital surface model)과 같은 다양한 지형 모델이 그 역할을 수행하고 있다 (Guth et al., 2021).

그중 DSM은 건물, 수목과 같은 모든 인공 및 자연물의 고도 정보를 포함하고 있어 도시 계획, 홍수 시뮬레이션, 환경 모니터링 등 정밀 분석이 필요한 분야에서 널리 활용된다 (Ye et al., 2023). 특히 홍수파 해석에서는 단순 고도 데이터보다 다양한 지형 요소를 반영한 DSM이 중요한 역할을 한다. 현재의 고해상도 DSM 구축 방식은 주로 위성, UAV를 활용한 SfM-MVS (structure-from-motion & multi-view stereo), LiDAR에 의존하고 있다. 예를 들어 SfM-MVS 기법은 센티미터 단위의 해상도를 가진 고해상도 DSM을 구축할 수 있으며, UAV는 저고도에서도 운용이 가능한 특징으로 다양한 환경에서 광범위하게 사용되고 있다.

그러나 이러한 고해상도 DSM 구축에는 한계가 따른다. 첫째, SfM-MVS 또는 LiDAR 기반의 DSM 구축은 촬영 장비와 인력, 현장 조사 자원

등 많은 비용과 시간이 소요된다. 둘째, 배터리 기술의 한계로 인해 UAV가 한 번에 촬영할 수 있는 범위는 제한적이며, 기상 조건이나 지형 장애물에 따라 촬영 자체가 어려울 수 있다. 셋째, 지형 데이터를 후처리하고 일관성을 유지하는 작업이 고도로 훈련된 인력과 고성능 컴퓨팅 자원을 필요로 한다. 따라서 재난 관리를 위한 효율적이고 지속적인 지형 데이터 구축을 위해서는 새로운 대안이 필요하다.

최근 인공지능 기술의 발전으로 이미지를 다양한 형태의 데이터로 변환하는 생성형 모델이 주목받고 있다. 대표적인 생성형 모델로는 GAN (generative adversarial networks)과 Diffusion 모델이 있다. GAN은 생성자와 판별자를 학습시켜 이미지 간 변환을 가능하게 하고, Diffusion 모델은 시간의 흐름에 따른 이미지 변환 과정을 학습하여 더욱 정교한 변환이 가능하다 (Bond-Taylor et al., 2021). 이러한 생성형 모델들은 텍스트-이미지 생성, 인페인팅, 초해상도 등에서 기존 방법보다 뛰어난 성능을 보여주고 있다 (Dhariwal & Nichol, 2021). 이러한 발전을 기반으로 본 연구는 단일 광학 이미지를 이용하여 고해상도 3차원 지형 데이터를 자동 생성하는 인공지능 기반의 새로운 접근법을 탐색하였다.

본 고에서는 단일 광학 이미지를 입력받아 학습할 수 있는 생성형 AI 모델을 개발하고, 이를 활용해 신속하게 3차원 지형 데이터를 생성하는 방법론을 제안한다. 이는 기존의 SfM-MVS와 LiDAR 기반 DSM 구축 방식이 가진 비용과 자원 문제를 해결하고, 재난 관리에서 필요로 하는 광범위한 지형 데이터를 자동으로 생성할 수 있는 가능성을 제시한다.

2. SfM-MVS를 활용한 학습데이터 구축

본 연구에서는 입력된 광학 이미지에서 DSM의 정확한 변화에 초점을 맞추기 위해 지도 학습 (supervised learning) 방법을 적용하였다. 이는 정사영상과 DSM 데이터의 페어 데이터를 활용하여 입력과 출력 간의 직접적인 매핑을 학습하는 것이다. 또한 광학 이미지는 정사영상 (orthoimage)을 사용함으로써 학습 데이터의 기하학적 정확성과 일관성을 유지하였다.

모델 학습에 필요한 DSM Ground truth 데이터는 SfM-MVS 기법을 사용하여 구축하였다. 지형의 특성을 정밀하게 반영하기 위해 촬영 조건과 SfM-MVS 매개변수를 최적화하여 고해상도 DSM을 생성하였으며, 지형의 재현성을 높이는 데 주안점을 두었다. 확보된 Ground truth는 주요 객체의 형태와 고도 정보를 충분히 반영하여 모델 학습에 적합한 데이터를 활용하였다. 이를 위해 촬영 고도, 영상 중복도, 촬영 각도 등의 변수를 조정하여 최적의 촬영 조건을 선정하였다. GSD (ground sample distance)를 2.5cm/pixel로 유지하고, 영상 중복도는 80%로, 촬영각도는 55°로 설정하여 지형의 세부 묘사와 배터리 사용 효율 간의 균형을 맞추었다. 이렇게 구축된 DSM은 다양한 지형 요소 (건물, 수목, 도로, 하천 등)를 포함하고 있어 모델이 지형의 깊이와 구조적 특성을 학습하는 데 적합한 데이터를 제공하였다.

딥러닝을 위한 데이터 학습은 다양한 위치의 픽셀을 골고루 반영할 수 있도록 지역 내의 랜덤함수를 사용하여 시작 포인트를 지정하였다. 지정된 랜덤 시작 포인트를 중앙으로 픽셀의 사이즈가 256×256인 이미지가 생성되며, 이때 이미지의 여백 (nodata)이 25% 이상인 데이터들은 제외하였다. 256×256 사이즈로 생성된 DSM 데이터를

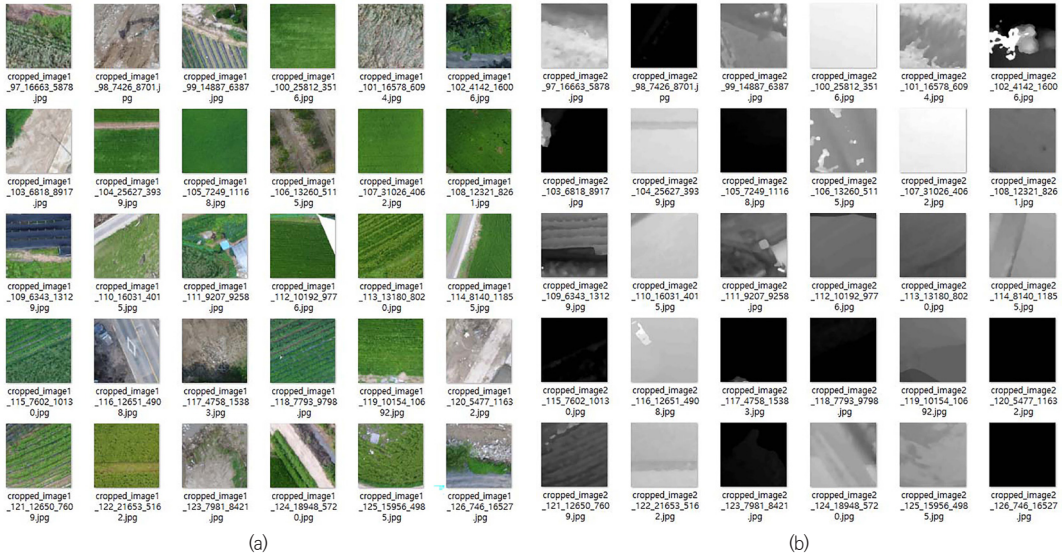


Fig. 1 Example data set for model training. (a) RGB data set cropped and padded to 256×256 size, and (b) preprocessed DSM data set at the same coordinates as the RGB data

대상으로 도메인의 최하단 좌측부분의 x, y 좌표를 (1,1)이라고 설정했을 때, 각 DSM 마다 가지는 고유한 x, y 좌표를 나타낼 수 있도록 하였다. 이는 각 데이터 조각이 원본 DSM 내에서 어디에 위치하는지를 나타내주는 고유 식별자 역할을 한다 (Fig. 1).

또한, 데이터 증강 기법 (data augmentation)을 통해 명도나 채도 등을 조금씩 변화시켜 학습 데이터의 다양성을 확보하였다. 이를 통해 모델이 다양한 조건에서 더욱 강인하게 학습될 수 있도록 하였다. 증강 기법은 이미지의 회전을 통한 기하학적 변환 방법과 이미지의 명도, 대비, 채도를 조정하는 색상 변환법을 택하여 회전과 명도, 채도를 $\pm 20\%$ 씩 데이터에 적용하여 학습 데이터 세트에 추가하였다. 이러한 변형을 통해 모델이 실제 환경에서의 다양한 변화를 고려할 수 있도록 하였다. 또한 각 데이터는 절대 고도 차이로 인해 학습 시 노이즈가 발생하므로, 상대적인 고도 범위 추정을 위해 모든 대상지는 고도차이를 표준화

하여 최대 고도와 최소 고도의 차이가 같은 간격을 가지도록 범위를 설정하였다.

3. 단일 영상 지형 생성 모델 개발

3.1 CycleGAN 기반 지형 생성

CycleGAN (cycle-consistent generative adversarial networks)은 두 도메인 간의 이미지 변환을 위해 구축된 GAN 기반 생성형 AI 모델이다 (Zhu et al., 2017). 모델은 생성자 (generator)와 판별자 (discriminator)로 구성되며, 생성자는 입력 이미지로부터 다른 도메인의 이미지를 생성하고, 판별자는 생성된 이미지의 진위 여부를 판단한다 (Eq. 1).

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z)))] \quad (1)$$

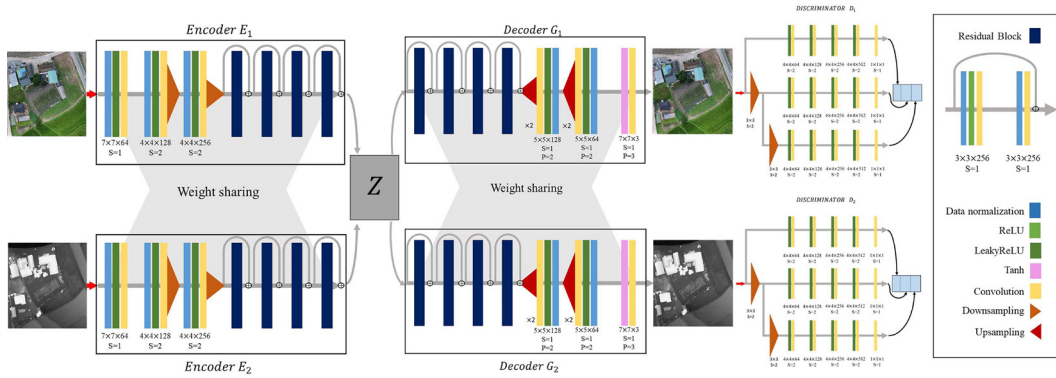


Fig. 2 Model architecture of CycleGAN generating the DSM data from single terrain orthoimage

여기서, $V(D, G)$ 는 목적함수를 나타내며, D 는 판별자로서 입력 이미지가 실제 데이터일 확률을 반환한다. 첫 번째 항 $E_{x \sim p_{data(x)}}[\log D(x)]$ 은 실제 데이터 x 를 판별자에 입력했을 때의 기대값을, $E_{\zeta \sim p_{\zeta}}[\log(1 - D(G(\zeta)))]$ 는 생성자가 잠재 벡터 ζ 로부터 생성한 이미지 $G(\zeta)$ 를 판별자에 입력했을 때의 기대값을 나타낸다. 판별자 D 가 실제 데이터를 정확히 분류할수록 $D(x) \approx 1$ 이 되며, 목적함수가 커진다. 마찬가지로 생성된 데이터를 가짜로 분류할수록 $D(G(\zeta)) \approx 0$ 이 되며, 목적함수가 커진다. 반대로 생성자는 판별자를 속이기 위해 생성된 데이터 $G(\zeta)$ 에 대해 $D(G(\zeta))$ 가 1에 가까워지도록 데이터를 생성하여 목적함수를 최소화하려고 한다. 결국, 생성자와 판별자는 이 가치 함수 $V(D, G)$ 를 두고 서로 경쟁하며, 이 과정에서 생성자는 점점 더 실제 데이터와 구별하기 어려운 DSM을 생성하게 된다. 또한 CycleGAN은 사이클 일관성 (Cycle Consistency)을 유지하도록 설계되어, 한 도메인에서 다른 도메인으로 변환된 후 다시 원래 도메인으로 복귀했을 때, 원본 이미지와 유사하도록 추가적인 학습이 이루어진다 (Fig. 2).

3.2 BBDM 기반 지형 생성

BBDM (brownian bridge diffusion model)은 확률적 생성 모델인 Diffusion 모델의 일종으로, 브라운 운동 브리지 (brownian bridge) 과정을 활용하여 이미지 변환을 학습한다 (Li et al., 2023). 이 모델은 입력 이미지에서 점진적으로 노이즈를 추가하고 제거하는 과정을 통해 복잡한 데이터 분포를 학습한다. 특히 시작점과 끝점을 고정된 상태에서 확률적 경로를 생성하므로, 입력 이미지와 목표 이미지 간의 직접적인 변환이 가능하다. x_0 는 입력 이미지로써 브라운 운동 과정의 시작점을, y 는 DSM으로써 목표점이라고 할 때, 브라운 운동 브리지 과정은 Eq. 2와 같이 x_0 와 y 가 조건부 확률로 들어가며, t 스텝이 지남에 따라 x_0 에서 y 로의 평균이 변하는 과정을 나타낸다. 또한 모델은 Eq. 4와 같이 CycleGAN과 마찬가지로 변환된 데이터를 원래의 시작점으로 되돌리는 역확산과정을 거쳐 모델의 일반화 능력을 향상시킨다.

$$q_{BB}(x_t|x_0, y) = N(x_t; (1 - \frac{t}{T})x_0 + \frac{t}{T}y, \delta_t I) \quad (2)$$

$$\delta_t = 2 \left(\frac{t}{T} - \left(\frac{t}{T} \right)^2 \right) \quad (3)$$

$$p_\theta(x_{t-1}|x_t, y) = N(x_{t-1}; \mu_\theta(x_t, t), \delta_t I) \quad (4)$$

$\mu_\theta(x_t, t)$ 는 브라운 운동 브리지 과정에서 시간에 따른 상태의 변화를 나타내기 위해 사용된다. 이는 Eq. 5와 같이 중간 과정에서의 노이즈를 확인하여 목표치로 다가가기 위한 조절을 통해 모델의 성능을 최적화한다.

$$\mu_\theta(x_t, t) = c_{x_t} x_t + c_y y + c_{\varepsilon_t} \varepsilon_t(x_t, t) \quad (5)$$

$$c_{x_t} = \frac{\delta_{t-1}}{\delta_t} \left(1 - \frac{t}{T} \right) + \frac{\delta_{t|t-1}}{\delta_t} \left(1 - \frac{t-1}{T} \right) \quad (6)$$

$$c_y = \left(\frac{t-1}{T} - \frac{t}{T} \right) \frac{\delta_{t-1}}{\delta_t} \quad (7)$$

$$c_{\varepsilon_t} = \left(1 - \frac{t-1}{T} \right) \frac{\delta_{t|t-1}}{\delta_t} \quad (8)$$

여기서, c_{x_t} 는 현재 시점 t 에서의 상태 x_t 와 이전 시점 x_{t-1} 사이의 관계를 나타내고, c_y 는 목표 상태 y 가 현재 상태 x_t 에 미치는 영향을 나타낸다. c_{ε_t} 는 노이즈 ε_t 가 현재 상태 x_t 에 미치는 영향을 나타내며, δ_t 는 시간 t 에서의 분산, ε_t 는 표준 정규 분포 $N(0, I)$ 를 따르는 가우시안 노이즈를 의미한다. 즉, t 스텝이 지남에 따라 x_0 에서 y 로의 평균이 변하게 된다.

또한 모델은 이미지의 복원 성능을 높이기 위해, VQGAN (vector quantized generative adversarial network)으로 구성된 잠재 공간 (latent space)에서 벡터 양자화 (vector quantization)를 통해 입력된 특징 벡터들을 저차원 벡터로 표현화하고, 코드북에 학습된 벡터들을 비교 (self-

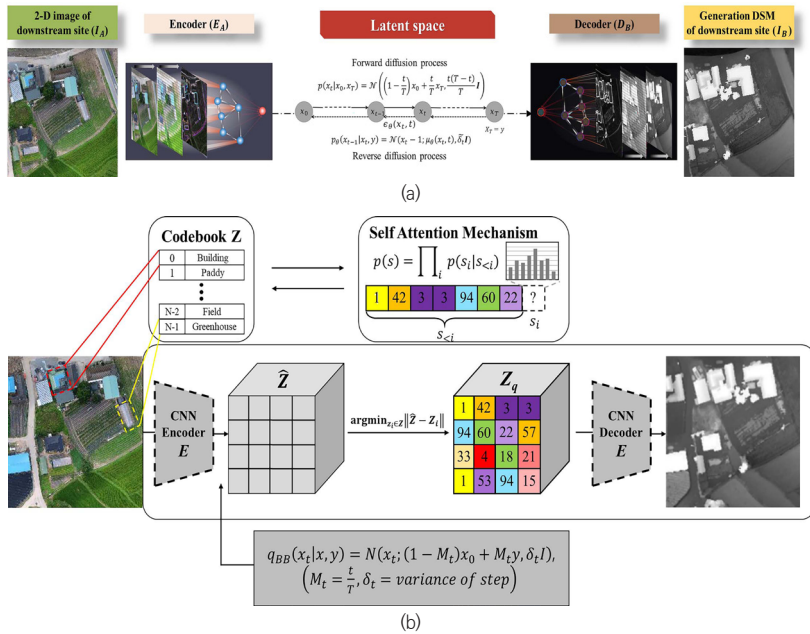


Fig. 3 Conceptual diagram of the DSM data generation by the BBDM model developed based on the brownian bridge process.

(a) Learning orthoimage to terrain data transformation through forward and reverse diffusion processes, (b) Terrain data restoration method based on vector quantization via self-attention mechanism in VQGAN constructed with BBDM latent space

attention mechanism)하여 가장 유사한 벡터로 대체한다. 이를 통해 이미지의 구조적 특징과 깊이 정보를 정밀하게 반영하도록 학습되며, 이를 디코딩하여 최종적인 DSM을 생성한다.

4. 지형 생성 모델 구축 및 재현성 평가

각 모델의 평가 지표로는 SSIM (structural similarity index measure), PSNR (peak signal to noise ratio), LPIPS (learned perceptual image patch similarity)을 사용하였다. 세 지표는 각기 다른 측면에서 이미지 품질을 평가하며, 많은 선행연구에서 이미지 재현성 평가를 위한 지표로써 유효성이 입증되어 사용되고 있다 (Ding et al., 2021).

단일 정사영상을 토대로 CycleGAN을 이용하여 DSM으로 재현한 결과는 Table 1과 같다. 지형의 세부 특징의 재현성을 평가하기 위해 작물만 존재하는 경우, 건축물이 혼재되어 존재하는 경우, 도로나 하천이 존재하는 경우 등으로 구분하여 평가하였다. 전반적으로 복잡한 지형의 연속적인 분포에서 객체별 세부적인 특징을 캐치하였으며, 이를 통해 객체별 깊이가 구분이 가능할 수준으로 지형자료가 생성된 것으로 확인되었다. 그러나 SSIM, PSNR, LPIPS 지표를 이용한 재현성 평가 결과 평균 SSIM은 0.3522, PSNR은 11.2477, LPIPS는 0.5939로 실제 데이터와의 유사성이 비교적 낮은 것으로 나타났다.

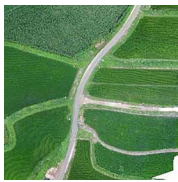


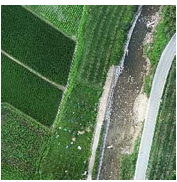
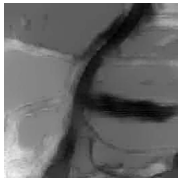





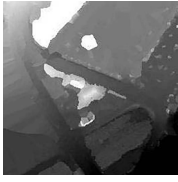
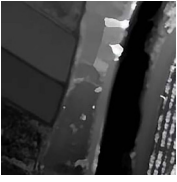



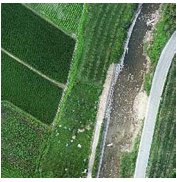
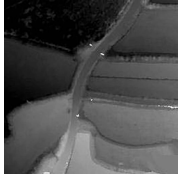


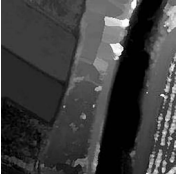
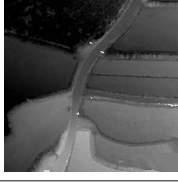

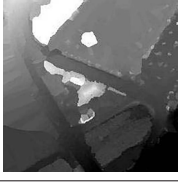
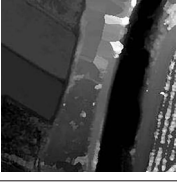
각 지표별 작물, 구조물, 도로, 하천에 대한 지형 특징을 재현하는 경우 평균 SSIM은 작물 0.3319, 구조물 0.3413, 도로 0.3482, 하천 0.3875로 나타났다. PSNR의 경우 작물 11.1987, 구조물 11.1432, 도로 10.2249, 하천 12.4241로 나타났다. LPIPS의 경우 작물 0.6270, 구조물

0.5587, 도로 0.5659, 하천 0.6239로 나타났다. 전반적으로 하천이 다른 경우보다 구조적 유사성이 높게 평가되었으며, 이는 비교적 균일한 패턴을 가지고 있어 구조적으로 학습이 잘 된 것으로 판단된다. 반면 작물의 경우 개별 작물의 패턴과 질감을 인식하고 재현하는 능력이 다소 부족하여 개선이 필요하다고 판단된다.

반면, BBDM을 통해 생성된 DSM은 밭, 주택, 도로, 온실 등의 모든 세부 객체들의 형태를 캡처하여 경계가 뚜렷하게 묘사되었으며, 고도 또한 Ground truth와 비교해 큰 차이를 보이지 않았다. 또한 산지 등 연속적인 고도 변화를 자연스럽게 재현해내었으며, 고도가 어느 한쪽으로 치중되지 않고 넓은 범위에서 고르게 나타났다 (Table 1).

각 지표별로 SSIM의 전체 평균값은 0.8545, PSNR은 23.2362, LPIPS는 0.1969로 전반적으로 구조적, 시각적 유사성이 매우 높고, 노이즈가 낮았다. 이는 드론으로 여러 장의 사진을 촬영하여 구축한 Ground Truth와 비교하여, 단일 이미지로부터 생성된 지형 데이터의 정확도가 약 90% 수준까지 근접했음을 의미한다. 즉, 기존 많은 시간과 높은 비용이 요구되는 드론 기반 방법과 비교하여 정확도가 매우 향상되었으며, 모델이 지형의 세부 특징과 형상을 효과적으로 재현했음을 보여주었다. 하천의 경우 SSIM 0.9116, PSNR 30.7461, LPIPS 0.1163으로 가장 우수한 재현성을 보였으며, 이는 BBDM이 하천의 특징을 효과적으로 인식하고, 구조적, 시각적 유사성을 잘 유지할 수 있었다고 분석된다. 구조물의 경우에도 SSIM 0.8423, PSNR 24.8287, LPIPS 0.1568로 다른 객체에 비해 엷지인식이 매우 용이하여 전반적으로 높은 성능이 나타난 것으로 분석되었다. 작물의 경우 SSIM 평균값은 0.8619였으며, PSNR은 18.5203, LPIPS는 0.2784로 구조적 유

Table 1 Example of terrain data generation results using CycleGAN and BBDM according to terrain features (crops, structures, roads, stream)

Model	Case	Crops	Structures	Roads	Stream
Cycle GAN	Ortho image				
	Results				
	Ground truth				
	SSIM	0.396299	0.392551	0.475052	0.346304
	PSNR	11.07900	11.88263	11.42806	11.57849
	LPIPS	0.525112	0.538245	0.486887	0.543430
BBDM	Case	Crops	Structures	Roads	Stream
	Ortho image				
	Results				
	Ground truth				
	SSIM	0.915028	0.86411	0.715089	0.907223
	PSNR	26.00278	26.95648	13.16209	27.28426
	LPIPS	0.147724	0.149683	0.379717	0.118174

사성은 높으나, 시각적 유사성과 노이즈율이 전체 평균에 비해 평가가 낮게 나타났다. 이는 작물 이미지의 복잡한 패턴으로 인해 노이즈가 발생하였으며, 이에 따른 시각적 유사성이 다소 낮아진 것으로 분석되었다. 도로의 경우 SSIM 0.8023, PSNR 18.8498, LPIPS 0.2362로 전체 평균에 비해 낮은 성능을 보였다. 이는 도로의 표고가 낮아 경계가 다른 객체보다 뚜렷하지 않기에 정확한 경계를 인식하고 재현하는데 다소 어려움이 있었던 것으로 분석된다. 그럼에도 불구하고, 전체적으로 평가 점수가 우수하며, BBDM의 재현성이 전반적으로 높은 것으로 평가된다.

5. 결론

본 고에서는 재난 관리 분야에서 정밀한 DSM을 구축하고 기존 방식의 한계를 해결하기 위한 새로운 방법론을 제안하였다. 단일 이미지로부터 고해상도 지형 데이터를 효율적으로 생성하는 생성형 AI 모델을 개발하여, 비용, 시간, 인력 자원 등의 제약을 극복하고 광범위한 지역의 지형 데이터를 신속하게 구축할 수 있는 가능성을 제시하였다.

광학 이미지의 복잡한 패턴을 정확하게 학습하고 DSM을 생성하기 위해, 이미지 간 변환 성능이 우수한 CycleGAN과 BBDM을 생성 모델로 채택하여 비교하였다. CycleGAN은 생성자와 판별자의 적대적 학습 구조를 활용하여 이미지 간 변환을 학습하였으며, 두 도메인 간의 변환을 학습하여 이미지 간의 복잡한 변환 관계를 학습할 수 있다. 그러나 모델의 재현성 평가 결과, 노이즈로 인한 표고 오차와 객체 경계의 모호함으로 인해 작물, 도로, 하천, 구조물 등 세부 특징을 정밀하게 재현하는데 한계가 있었다.

반면, BBDM은 브라운 운동 브리지 과정과 같이 시작점과 끝점을 고정하고, 시간적 단계에 따른 랜덤 변화를 도입하여 다양한 변환 과정을 학습하였으며, 특히 중요한 지형 특징들을 의미론적으로 분할하여 벡터로 표현하고, 잠재 공간의 코드북과 비교하여 일치하도록 조정함으로써 지형의 구조적 특징과 연속적인 변화를 정확하게 재현할 수 있었다.

따라서 본 연구에서는 UAV 운용과 이미지 정합 과정 없이, 단일 이미지로부터 고해상도 3차원 지형 데이터를 생성할 수 있는 대안으로 BBDM을 최종 채택하였다. 이를 통해 지표면의 객체들을 정밀하게 표현하면서도, 지형 자료 구축에 필요한 자원 소모와 시간을 획기적으로 단축할 수 있었다.

이러한 접근 방식은 특히, 기존의 UAV으로 여러 장의 사진을 촬영하고 업로드하는 SfM-MVS 방식과 비교하여 지형자료 생성 속도와 비용 부분이 크게 향상되었으며, 생성된 지형 데이터는 UAV로 구축한 Ground Truth와 약 90% 이상의 유사성을 보여, 모델이 실제 지형의 세부 특징과 형상을 정밀하게 재현할 수 있음을 확인하였다. 이를 통해 촬영 장비나 현장 조사에 대한 의존도를 크게 낮추면서도, 정확하고 신뢰성 있는 지형 데이터를 효율적으로 구축할 수 있음을 입증하였다. 또한, 재난 관리에서 필요한 광범위한 지형 데이터를 신속하게 확보함으로써, 재난 대비와 대응에 중요한 역할을 할 것으로 기대된다. 실제로 생성된 지형 데이터를 활용하여 3차원 홍수와 해석을 수행할 수 있었으며, 이를 통해 모델의 적용성이 매우 뛰어남을 확인하였다.

그러나 본 연구의 지형 생성 방법은 여름철 저수지 하류부 지형 재현에 한정되었으며, 계절 변화에 따른 식생의 변화는 반영하지 못하였다. 또한 농촌 지역에 특화되어 있어, 고층 빌딩이나 사

유 시설이 존재하는 도시 지역에는 적용이 제한된다. 향후 연구에서는 다양한 지형 환경과 계절적 변화를 반영한 데이터셋을 추가로 구축하고, 모델의 일반화 능력을 향상시켜 실제 재난 관리 시스템에 적용할 수 있는 실용적인 솔루션을 몇 년 내에 개발할 예정이다. 이를 통해 재난 관리 분야에서 실질적인 활용이 가능하도록 시스템을 완성하고자 한다.

참고문헌

1. Daud, M., Ugliotti, F. M., & Osello, A. (2024). Comprehensive analysis of the use of Web-GIS for natural hazard management: A systematic review. *Sustainability*, 16(10), 4238. <https://doi.org/10.3390/su16104238>
2. Ugliotti, F. M., Osello, A., Daud, M., & Yilmaz, O. O. (2023). Enhancing risk analysis toward a landscape digital twin framework: A multi-hazard approach in the context of a socio-economic perspective. *Sustainability*, 15(16), 12429. <https://doi.org/10.3390/su151612429>
3. Guth, P. L., Van Niekerk, A., Grohmann, C. H., Muller, J. P., Hawker, L., Florinsky, I. V., ... & Strobl, P. (2021). Digital elevation models: Terminology and definitions. *Remote Sensing*, 13(18), 3581. <https://doi.org/10.3390/rs13183581>
4. Ye, J., Qiang, Y., Zhang, R., Liu, X., Deng, Y., & Zhang, J. (2021). High-precision digital surface model extraction from satellite stereo images fused with ICESat-2 data. *Remote Sensing*, 14(1), 142. <https://doi.org/10.3390/rs14010142>
5. Bond-Taylor, S., Leach, A., Long, Y., & Willcocks, C. G. (2021). Deep generative modelling: A comparative review of VAEs, GANs, normalizing flows, energy-based and autoregressive models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(11), 7327–7347. <https://doi.org/10.1109/TPAMI.2021.3116668>
6. Dhariwal, P., & Nichol, A. (2021). Diffusion models beat GANs on image synthesis. *Advances in Neural Information Processing Systems*, 34, 8780–8794. <https://doi.org/10.48550/arXiv.2105.05233>
7. Li, B., Xue, K., Liu, B., & Lai, Y. K. (2023). BBDM: Image-to-image translation with Brownian bridge diffusion models. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 1952–1961. <https://doi.org/10.1109/CVPR52729.2023.00194>
8. Zhu, J. Y., Park, T., Isola, P., & Efros, A. A. (2017). Unpaired image-to-image translation using cycle-consistent adversarial networks. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2242–2251. <https://doi.org/10.1109/ICCV.2017.244>